

Despliegue de un modelo de MACHINE LEARNING

Introducción

Los modelos de Machine Learning (ML) se utilizan de forma creciente en el ámbito bancario para identificar patrones anómalos y predecir transacciones fraudulentas en tiempo real.

Sin embargo, el despliegue de un nuevo modelo conlleva riesgos operativos y de negocio:

- **Falsos positivos**, que generan bloqueos en compras legítimas y afectan la experiencia del cliente.
- **Falsos negativos**, que permiten que fraudes reales pasen inadvertidos.

Este trabajo propone un plan de despliegue seguro, controlado y reversible que combina prácticas de ingeniería y monitoreo continuo para reemplazar el modelo vigente sin comprometer la estabilidad del sistema.

El enfoque se basa en una estrategia gradual de validación en producción, con métricas de desempeño, auditoría y mecanismos de retroceso inmediato ante desviaciones críticas.

Los resultados evidencian que un despliegue planificado y supervisado no solo reduce el riesgo operativo, sino que también mejora la detección temprana de fraudes y preserva la confianza del cliente.

En entornos financieros, la calidad del despliegue es tan determinante como la precisión del modelo.

GRUPO 3 - INTEGRANTES

Escudero Jeremias
Atala Julieta Belén
Alejo Herrera
Perez Alvaro
Jeremías Caleb
Baudino Martin

Objetivos del Proyecto

- Minimizar riesgos al reemplazar el modelo actual por uno más preciso.
- Garantizar que el despliegue no afecte operaciones críticas ni a los clientes.
- Utilizar estrategias de despliegue que permitan observar el modelo antes de activarlo totalmente.
- Establecer un sistema de monitoreo que detecte a tiempo errores, degradación o drift del modelo.
- Asegurar un rollback inmediato en caso de comportamientos anómalos.
- Implementar buenas prácticas de DevOps, MLOps y seguridad bancaria.

Infraestructura y Entorno

- Contenedores Docker para asegurar portabilidad del modelo.
- Kubernetes para orquestación, escalado y alta disponibilidad.
- API Gateway para controlar el tráfico y permitir Canary Releases.
- Entornos separados: Dev → QA → Producción, evitando riesgos en sistemas críticos.

Dependencias Técnicas

- Librerías de Machine Learning (XGBoost / Scikit-Learn / TensorFlow).
- Feature Store para servir las variables del modelo en tiempo real.
- Pipelines ETL para transformar transacciones en features.
- Servicios complementarios: logs, seguridad, autenticación, monitoreo.

Prerrequisitos del Despliegue

- Validación del dataset (calidad, sesgos, duplicados).
- Tests unitarios, integración, carga y estrés.
- Controles de seguridad: cifrado, roles de acceso, escaneo de vulnerabilidades.

Monitoreo Post-Despliegue

- Métricas técnicas: latencia, throughput, errores.
- Métricas de negocio: falsos positivos, falsos negativos, tasa de fraude detectado.
- Drift de datos: cambios en la distribución que afectan precisión.

Roles Involucrados

- Data Scientists: entrenamiento y evaluación del modelo.
- Data Engineers: pipelines y datos.
- MLOps/DevOps: CI/CD, despliegue, monitoreo.
- Equipo de Fraudes: validación funcional.
- Seguridad/Compliance: auditoría y normativas bancarias.

Conclusión

La implementación de modelos de Machine Learning en sistemas financieros requiere precisión técnica y control operativo. Este trabajo presenta una estrategia de despliegue seguro y reversible basada en Shadow Deployment, Canary Release y Feature Flags, que permite evaluar el rendimiento del nuevo modelo sin interrumpir el servicio.

El enfoque garantiza continuidad operativa, reducción de riesgos, mejor detección de fraudes y cumplimiento normativo, demostrando que el proceso de despliegue es tan crítico como el modelo mismo.

Materiales y Metodos

- Estrategias de Despliegue
- ✓ Shadow Deployment
- El modelo nuevo corre en paralelo, predice pero no decide.
- Permite comparar rendimiento real sin afectar a usuarios.
- ✓ Canary Release
- Activación progresiva: 1% → 5% → 10% → 25%...
- Se avanza sólo si las métricas se mantienen estables.
- ✓ Feature Flags
- Interruptores para habilitar o deshabilitar el modelo en menos de 1 segundo.
- Rollback instantáneo sin downtime.

MODELO ENTRENADO: FRAUD_MODEL_V3.2.PKL
VERSIONADO ANTERIOR PARA ROLLBACK: V2.9.PKL

Resultados

Shadow Deployment

- El modelo nuevo predijo en paralelo sin afectar decisiones reales.
- Se comparó con el modelo actual sobre tráfico real.
- Permitted detectar errores y ajustar antes del despliegue.

Feature Flags

- Cambio entre modelo viejo y nuevo en <1 segundo.
- Rollback automático ante desviaciones de métricas.
- Sin downtime ni redeploy.

Monitoreo completo

- Métricas técnicas: latencia, errores, throughput.
- Métricas de negocio: fraude detectado, FP y FN.
- Alertas de drift y dashboards en tiempo real.

Canary Release

- Inicio con 1% del tráfico → aumento progresivo.
- Control de falsos positivos, falsos negativos y latencia.
- Sin impacto en clientes durante el proceso.

Mejoras sobre el modelo anterior

- Mayor precisión en detección de fraude real.
- Menos bloqueos erróneos de clientes.
- Respuesta más rápida y estable.

